

Reporte de Rendimiento: RM-NSGA-II

Evaluación Exhaustiva vs. Baselines

Generado Automáticamente

15 de agosto de 2026

Resumen

Este documento presenta los resultados del benchmark realizado sobre el modelo **RM-NSGA-II** en comparación con varios clasificadores tradicionales (k-NN, Naive Bayes, SVM-RBF, Decision Tree). Se evalúa tanto el rendimiento predictivo (Accuracy y F1-Score) como la escalabilidad y tiempo de entrenamiento en datasets sintéticos y reales de diferente dimensionalidad.

1. Métricas de Precisión

El rendimiento del modelo evolutivo ha sido altamente competitivo. En algunos escenarios de alta dimensionalidad, el modelo alcanza un equilibrio óptimo debido a la optimización multiobjetivo (complejidad vs error).

Cuadro 1: Accuracy por Dataset y Clasificador

Dataset	RM-NSGA-II	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 $\gamma=1.00$)	SVM-Linear (C=1)	Decision Tree (depth=8)
Two Moons (2D)	0.8750	0.9750	0.9875	0.8500	0.8750	0.8875	0.9750
Circles (2D)	1.0000	1.0000	1.0000	1.0000	1.0000	0.4125	1.0000
Spirals (2D)	0.6500	1.0000	1.0000	0.6375	0.6250	0.6500	0.9500
Blobs (2D)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Chessboard (2D)	0.5750	0.8000	0.8125	0.5375	0.5625	0.5375	0.7375
Adversarial(52D)	0.4375	0.4250	0.4875	0.7500	0.4125	0.4000	0.9875
Iris (4D)	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667
Wine (13D)	0.9714	1.0000	0.9714	0.9714	1.0000	1.0000	0.9143
BreastCancer(30D)	0.9381	0.9823	0.9823	0.9115	0.9823	0.9911	0.9204

Cuadro 2: F1-Score por Dataset y Clasificador

Dataset	RM-NSGA-II	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 $\gamma=1.00$)	SVM-Linear (C=1)	Decision Tree (depth=8)
Two Moons (2D)	0.8737	0.9742	0.9870	0.8420	0.8698	0.8844	0.9740
Circles (2D)	1.0000	1.0000	1.0000	1.0000	1.0000	0.2920	1.0000
Spirals (2D)	0.5611	1.0000	1.0000	0.6305	0.6190	0.6444	0.9497
Blobs (2D)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Chessboard (2D)	0.5747	0.7995	0.8125	0.5368	0.5152	0.5099	0.7324
Adversarial(52D)	0.3524	0.4217	0.4874	0.7421	0.2920	0.3966	0.9870
Iris (4D)	0.9680	0.9680	0.9680	0.9680	0.9680	0.9680	0.9680
Wine (13D)	0.9734	1.0000	0.9710	0.9696	1.0000	1.0000	0.9148
BreastCancer(30D)	0.9281	0.9790	0.9790	0.8965	0.9790	0.9894	0.9076




Figura 1: Comparación gráfica de Accuracy entre clasificadores.

2. Análisis de Tiempos de Entrenamiento

A continuación se muestra el tiempo de convergencia del modelo evaluado en una escala logarítmica para contextualizar el comportamiento asintótico frente a modelos deterministas (e.g. SVM). Gracias a las recientes optimizaciones (OpenMP, early stopping y caching de proyecciones), el algoritmo mantiene tiempos escalables.

Cuadro 3: Tiempo de Entrenamiento (ms) por Dataset y Clasificador

Dataset	RM-NSGA-II	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 $\gamma=1.00$)	SVM-Linear (C=1)	Decision Tree (depth=8)
Two Moons (2D)	4189	0	0	0	55	21	26
Circles (2D)	4856	0	0	0	92	28	31
Spirals (2D)	4160	0	0	0	84	24	44
Blobs (2D)	3945	0	0	0	20	12	12
Chessboard (2D)	4196	0	0	0	70	29	36
Adversarial(52D)	49918	0	0	0	426	767	1175
Iris (4D)	2627	0	0	0	10	3	1
Wine (13D)	6507	0	0	0	67	16	21
BreastCancer(30D)	41315	0	0	0	975	324	1003




Figura 2: Tiempo de entrenamiento (escala logarítmica) requerido por cada clasificador.

3. Análisis del Manifold y Fronteras de Pareto

La característica distintiva del RM-NSGA-II es el aprendizaje de una frontera de decisión basada en coeficientes de Fourier de longitud variable. El frente de Pareto refleja el compromiso entre la precisión del modelo y la complejidad intrínseca del mismo (medida mediante la longitud de arco y el número de armónicos).




Figura 3: Ejemplo del Frente de Pareto de la población en la última generación.




Figura 4: Proyección bidimensional del manifold y las fronteras generadas sobre los datos de prueba.