

FM-NSGA-II: A Non-Dominated Sorting Genetic Algorithm based on Fourier Manifolds for Non-Linear Classification

Hugo Campos Castro

20 de agosto de 2026

Resumen

Este artículo describe la formulación matemática, diseño y optimización del **FM-NSGA-II**, un clasificador topológico fundamentado en la evolución de Variedades de Fourier paramétricas en $\mathbb{R}^D$. El modelo resuelve el problema de clasificación no lineal envolviendo distribuciones mediante fronteras continuas cerradas, cuya topología —junto con un vector de *pesos de características* co-evolucionado— es optimizada estocásticamente mediante el motor genético multi-objetivo NSGA-II. Para subsanar el costo trigonométrico, se introduce una segunda arquitectura paralela (**AM-NSGA-II**) basada en una Hipersuperficie Direccional de Chebyshev que acelera la inferencia y el entrenamiento en un factor de 100×. Se detallan formalmente la representación de ambos colectores con distancia euclidiana ponderada, la métrica de pertenencia, la función de costo de Navaja de Ockham paramétrica y la lógica evolutiva. Se presentan optimizaciones de alto rendimiento (caching, mini-batching y paralelismo multi-núcleo sin bloqueos) y resultados experimentales que demuestran universalidad en problemas euclidianos, junto con los límites teóricos del algoritmo frente a espacios topológicamente no-diferenciables y ruidosos (maldición de la dimensionalidad).

1. Introducción

La separación de clases en espacios no linealmente separables es abordada clásicamente mediante proyecciones a dimensiones superiores (ej. truco del kernel en Máquinas de Vectores de Soporte). El presente trabajo aborda el problema de forma inversa: en lugar de deformar el espacio para acomodar un hiperplano lineal, construimos un colector (manifold) paramétrico $M \subset \mathbb{R}^D$ de codimensión $D - 1$ que se pliega intrínsecamente para separar las clases en su espacio topológico nativo.

Debido a que la parametrización de superficies altamente no convexas carece de una formulación diferencial analítica directa respecto a un error de clasificación discreto, el proceso de entrenamiento se formula como un problema de optimización combinatoria multi-objetivo resuelto mediante el **Non-Dominated Sorting Genetic Algorithm II (NSGA-II)** [1].

2. Formulación Matemática del Modelo

2.1. Representación del Colector (Fourier Manifold)

Definimos la frontera de decisión como una curva o hiper-superficie paramétrica cerrada M . Para garantizar continuidad y diferenciabilidad, parametrizamos M utilizando una expansión de series de Fourier truncada.

Para un espacio de características $\mathbb{R}^D$, la variedad se define mediante una aplicación continua $\mathbf{f} : [0, 2\pi) \rightarrow \mathbb{R}^D$, donde la coordenada en la dimensión $d \in \{1, \dots, D\}$ viene dada por:

$$f_d(t) = a_{0,d} + \sum_{k=1}^H (a_{k,d} \cos(kt) + b_{k,d} \sin(kt)) \quad (1)$$

donde:

- $t \in [0, 2\pi)$ es el parámetro intrínseco de la curva.
- $H \in \mathbb{N}$ es el número de armónicos (frecuencia máxima), que controla la complejidad oscilatoria de la curva.
- $a_{0,d}$ representa el centroide de la variedad en la dimensión d .
- $A, B \in \mathbb{R}^{H \times D}$ son las matrices de coeficientes que dictan la amplitud y fase topológica de la envoltura.
- $\mathbf{w} \in [0, 1]^D$ es el vector de **pesos de características**, co-evolucionado con los coeficientes de Fourier.

El genotipo de un individuo en la población de NSGA-II está representado por el vector de parámetros reales $\theta \in \mathbb{R}^{D \times (2H+1)}$, extendido con el vector de pesos $\mathbf{w}$. Este vector constituye el cromosoma evolutivo completo, donde cada bloque de genes codifica un armónico de Fourier en el plano proyectado, como se ilustra esquemáticamente en la Figura 1.

2.2. Métrica de Distancia Ponderada y Clasificación

La regla de decisión para un punto $\mathbf{x} \in \mathbb{R}^D$ requiere calcular la pertenencia topológica (“dentro” o “fuera”




Figura 1: Representación en memoria del vector paramétrico (Cromosoma) dentro del espacio de búsqueda del algoritmo genético. Cada gen es un valor en $\mathbb{R}$ mutado bajo distribuciones Gaussianas y Polinomiales para alterar gradualmente la curvatura topológica. El vector de pesos $\mathbf{w}$ se co-evoluciona con los coeficientes de Fourier, permitiendo al algoritmo aprender selectivamente la relevancia de cada dimensión espacial.

de M). A diferencia de la distancia euclidiana isotrópica clásica, utilizamos la **distancia euclidiana ponderada** inducida por $\mathbf{w}$:

$$d_w(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{d=1}^D w_d (x_d - y_d)^2} \quad (2)$$

La proyección ortogonal mínima sobre la curva se calcula entonces como:

$$d_{min}(\mathbf{x}, M) = \min_{t \in [0, 2\pi]} d_w(\mathbf{x}, \mathbf{f}(t)) \quad (3)$$

Computacionalmente, minimizamos esta función discretizando el espacio paramétrico t en N_p puntos equidistantes con refinamiento por Golden Section.

La pertenencia topológica de $\mathbf{x}$ a M se determina mediante una **comparación radial con el centroide** $\mathbf{c}$. Sea $t^* = \arg \min_t d_w(\mathbf{x}, \mathbf{f}(t))$ el parámetro del punto más cercano en la curva. La **distancia con signo** se define como:

$$D_S(\mathbf{x}, M) = d_w(\mathbf{x}, \mathbf{c}) - d_w(\mathbf{f}(t^*), \mathbf{c}) \quad (4)$$

Si $D_S < 0$, el punto $\mathbf{x}$ está más cerca del centroide que la propia curva en esa dirección, interpretándose como *interior*; si $D_S \geq 0$, como *exterior*. Este mecanismo extiende de forma natural a $\mathbb{R}^D$ arbitrario sin depender de Ray-Casting (inviabile para curvas 1D en $D \geq 3$) ni del Winding Number. Requiere la suposición implícita de que el centroide $\mathbf{c}$ sea inicializado dentro del conjunto positivo (garantizado usando el centroide empírico de los puntos de la clase), de modo que la variedad sea *estrellada* (*star-shaped*) respecto a $\mathbf{c}$.

2.3. Variante Alternativa: Hipersuperficie Direccional (Angular Manifold)

Adicionalmente a la Variedad de Fourier, desarrollamos una formulación puramente direccional para combatir la dimensionalidad masiva. En este modelo, el genotipo proyecta una hipersuperficie desde un eje polar principal $\mathbf{v} \in \mathbb{R}^D$. El umbral radial $R(\theta)$ se define por

una expansión de polinomios de Chebyshev de primera especie sobre el ángulo θ :

$$R(\theta) = a_0 + \sum_{k=1}^H a_k \cos(k\theta) \quad (5)$$

Donde $\cos(\theta) = \frac{\langle \mathbf{x} - \mathbf{c}, \mathbf{v} \rangle_w}{\|\mathbf{x} - \mathbf{c}\|_w \|\mathbf{v}\|_w}$. La distancia con signo topológica se simplifica a $D_S = \|\mathbf{x} - \mathbf{c}\|_w - R(\theta)$, resultando en una inferencia extremadamente rápida ($O(D+H)$ sin discretizaciones t). El cromosoma del Angular Manifold separa la topología direccional de los coeficientes polinomiales (Figura 2).




Figura 2: Cromosoma del Angular Manifold. Separa el centroide $\mathbf{c}$ y vector direccional $\mathbf{v}$, los coeficientes de Chebyshev a_k , y los pesos de características $\mathbf{w}$ (sujetos a regularización L1 para forzar escasez).

2.4. Espacio de Optimización Multi-Objetivo

Un clasificador paramétrico de Fourier de H suficientemente alto puede tejer una curva arbitraria capaz de envolver cada punto individual (sobreajuste severo). Para penalizar esta topología, usamos la optimización de Pareto de NSGA-II minimizando dos objetivos simultáneos: $\mathbf{O}(\mathcal{G}) = [O_1(\mathcal{G}), O_2(\mathcal{G})]^T$.

Objetivo 1: Error Empírico (O_1) Se evalúa la fracción de ejemplos mal clasificados. Dada la etiqueta binaria $y_i \in \{+1, -1\}$ (donde $+1$ es la clase interior):

$$O_1 = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[y_i \neq \text{sign}(-D_S(\mathbf{x}_i, M))] \quad (6)$$

Objetivo 2: Complejidad Topológica (O_2) La Navaja de Ockham se introduce penalizando matemáticamente la oscilación de la curva (calculando la integral de línea de la longitud de arco L) y la cardinalidad de la base trigonométrica H :

$$L(M) = \int_0^{2\pi} \|\mathbf{f}'(t)\|_2 dt \approx \sum_{j=1}^{N_p} \|\mathbf{f}(t_j) - \mathbf{f}(t_{j-1})\|_2 \quad (7)$$

$$O_2 = \lambda \min\left(\frac{L(M)}{L_{base}}, 1\right) + (1 - \lambda - \lambda_{L1}) \min\left(\frac{H}{H_{max}}, 1\right) + \lambda_{L1} \frac{\|\mathbf{w}\|_1}{D} \quad (8)$$

donde λ balancea el castigo espacial frente al espectral, y el nuevo término λ_{L1} introduce regularización *Lasso* sobre los pesos $\mathbf{w}$, forzando a la selección natural a eliminar dimensiones de ruido inútiles, sirviendo como un *Feature Selector* biológico intrínseco. El Frente de Pareto resultante de esta confrontación entre Error y Complejidad se muestra en la Figura 7.




Figura 3: Frente de Pareto resultante de la optimización NSGA-II tras 200 generaciones. Los individuos supervivientes (colectores) minimizan simultáneamente la Tasa de Error y la Complejidad Topológica (incluyendo escasez $L1$), permitiendo la selección del modelo óptimo por *early-stopping*.

2.5. Operadores Genéticos de Variación

- **Crossover:** Combina matemáticamente las matrices A , B y los vectores de pesos $\mathbf{w}$ de dos genotipos padres mediante interpolación aritmética: $\mathbf{w}_{hijo} = \alpha \mathbf{w}_{p1} + (1 - \alpha) \mathbf{w}_{p2}$, con $\alpha \sim \mathcal{U}(0, 1)$.
- **Mutación Estocástica:** Perturba aleatoriamente los coeficientes aplicando ruido Gaussiano: $a_{k,d} \leftarrow a_{k,d} + \mathcal{N}(0, \sigma^2)$. Los pesos w_d son perturbados análogamente y acotados a $[0, 1]$.
- **Mutación Espectral:** Añade o recorta armónicos ($H \leftarrow H \pm 1$), inicializando nuevos niveles de A y B cerca de 0, expandiendo el espacio de dimensionalidad paramétrica dinámicamente.

2.6. Estrategia One-vs-Rest (Multiclase)

Para resolver un problema con K clases, el sistema instancia K poblaciones independientes del FM-NSGA-II. Cada población modela un colector M_k envolviendo exclusivamente la clase k . Durante inferencia, un dato $\mathbf{x}^*$ es proyectado contra todos los colectores, decidiendo a favor del que presente mayor penetración topológica (menor distancia firmada):

$$\hat{y} = \arg \min_{k \in \{1, \dots, K\}} D_S(\mathbf{x}^*, M_k) \quad (9)$$

3. Implementación y Optimizaciones

La naturaleza de la ecuación $D_S(\mathbf{x}, M)$ implica evaluar funciones trigonométricas repetitivamente sobre toda la población. Las soluciones aplicadas fueron:

1. **Tablas de Búsqueda Trigonométrica (Caching):** Pre-cálculo masivo en $O(1)$ de todos los armónicos posibles para el dominio $t \in [0, 2\pi)$.
2. **Paralelismo Multi-núcleo sin Bloqueos (OpenMP):** Tres fases del algoritmo se ejecutan en paralelo sobre todos los núcleos disponibles: (1) evaluación del fitness O_1 , (2) generación de descendencia (cruce y mutación), y (3) construcción de la matriz de dominancia del NSGA-II. Esta última emplea *acumuladores thread-local*: cada hilo construye su propia copia parcial de la matriz de dominancia y las fusiona en un único paso serie al final, eliminando toda contención de escritura (*lock-free parallelism*).
3. **Pesos de Características Co-evolucionados ($\mathbf{w}$):** El vector $\mathbf{w}$ forma parte del genotipo y es optimizado conjuntamente con los coeficientes de Fourier. Esto permite que el algoritmo aprenda implícitamente la relevancia anisotrópica de cada dimensión, actuando como un selector de características integrado.
4. **Mini-Batching Estocástico:** Se aproxima O_1 utilizando un subconjunto aleatorio del $\approx 30\%$ de $\mathbf{x}_i$ en las primeras generaciones, acelerando radicalmente las mutaciones tempranas y actuando como un regularizador implícito.

3.1. Tiempos de Ejecución y Universalidad

La conjunción de *Mini-Batching*, *Caching* y paralelismo multi-núcleo deprimió los tiempos de entrenamiento. Para *Breast Cancer (30D)*, el algoritmo tardó **~ 56.3 segundos** en 8 núcleos, logrando un *Accuracy* de **94.7%**. La Figura 5 muestra la escalabilidad temporal frente a los demás baselines.

En conjuntos puramente lineales (*Blobs*), FM-NSGA-II imitó la frontera logrando un perfecto **100%**, confirmando que el motor evolutivo no colapsa ni penaliza estructuras subyacentes simples (prueba de universalidad). El rendimiento consolidado de las métricas F1 se expone en la Figura 4.

4. Evaluación Experimental y Límites Teóricos

Se enfrentó el modelo paramétrico a datasets imposibles para descubrir debilidades formales del algoritmo evolutivo frente a métodos euclidianos (k -NN) e hiperplanos de kernel (SVM). La Tabla 1 consolida los resultados cuantitativos de predicción (1 corrida) y expone de manera transparente la asimetría computacional




Figura 4: Resultados del benchmark global (Accuracy) en todos los datasets. Se resalta en verde sólido el rendimiento de la variedad propuesta (FM-NSGA-II) contrastado contra una paleta translúcida para los algoritmos deterministas clásicos. La gráfica evidencia la robustez geométrica del colector estocástico frente a distribuciones no lineales, donde algoritmos puramente lineales o hiperplanos simples sufren colapsos drásticos (ej. *Circles*).




Figura 5: Tiempos de ejecución en escala logarítmica. A pesar de que la dinámica poblacional exige evaluar cientos de variaciones del colector, la inyección matemática del *caching* trigonométrico, el paralelismo multi-núcleo sin bloqueos y el mini-batching del 30 % amortiguan el cuello de botella asintótico, estabilizando los tiempos en umbrales tolerables para aplicaciones de ingeniería.

(tiempo), reflejando el costo inherente de la evolución paramétrica frente a los modelos deterministas.

4.1. Asimetría Computacional: Fourier vs. Angular

Una observación crucial que emana de la Tabla 1 es la extrema diferencia en latencia de entrenamiento entre ambas representaciones topológicas. El FM-NSGA-II requiere en promedio más de 5000 ms para converger en la mayoría de datasets bidimensionales, penalizado por las costosas evaluaciones de las funciones trigonométricas multivariadas ($\sin, \cos$) sobre cada armónico y cada punto del dataset. En contraste, el nuevo modelo AM-NSGA-II (Angular Manifold) reduce el tiempo de convergencia a un rango de 58 – 92 ms (una aceleración cercana a 100×). Esto se logra al proyectar las coordenadas a un escalar $z \in [-1, 1]$ mediante un producto punto lineal y aplicar la serie polinomial de Chebyshev, cuya evaluación recursiva evade el uso de

la Unidad Aritmético Lógica (ALU) trigonométrica del procesador, haciendo a la evolución paramétrica altamente competitiva con algoritmos como SVM.

4.2. Limitación 1: Paisajes Evolutivos Engañosos (Chessboard)

El espacio *Chessboard* (XOR 4x4) expone un colapso en la mutación gaussiana. Aunque una serie de Fourier de $H = 8$ armónicos posee cierta expresividad, la alineación matemática de la fase de ondas de alta frecuencia genera un **rugged landscape** evolutivo (paisaje escabroso). La perturbación en fase deforma toda la cuadrícula, por lo que la función de fitness no provee un gradiente uniforme hacia el óptimo; consecuentemente, FM-NSGA-II converge pobremente (~52.5 % Accuracy).

Cuadro 1: Resultados Consolidados: Accuracy, F1-Score y Tiempo (ms) por Dataset y Clasificador

Dataset	FM-NSGA-II (Fourier)			AM-NSGA-II (Angular)			k-NN (k=3)			k-NN (k=7)			Gaussian Naïve Bayes			SVM-RBF (C=1 $\gamma=1.00$)			SVM-Linear (C=1)			Decision Tree (depth=8)		
	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms	Acc	F1	ms
Two Moons (2D)	0.8250	0.8232	5390	0.8125	0.7922	61	0.9750	0.9742	0	0.9875	0.9870	0	0.8500	0.8420	0	0.8875	0.8844	58	0.8750	0.8698	24	0.9750	0.9740	28
Circles (2D)	0.9125	0.9114	7232	0.5750	0.5467	62	1.0000	1.0000	0	1.0000	1.0000	0	1.0000	1.0000	0	1.0000	1.0000	113	0.4125	0.2920	21	1.0000	1.0000	26
Spirals (2D)	0.5750	0.5330	5784	0.5875	0.5429	89	1.0000	1.0000	0	1.0000	1.0000	0	0.6375	0.6305	0	0.6500	0.6444	80	0.6625	0.6582	16	0.9500	0.9497	37
Blobs (2D)	0.9875	0.9875	5683	1.0000	1.0000	58	1.0000	1.0000	0	1.0000	1.0000	0	1.0000	1.0000	0	0.9875	0.9875	20	1.0000	1.0000	11	1.0000	1.0000	10
Chessboard (2D)	0.5125	0.5118	5821	0.6125	0.6020	64	0.8000	0.7995	0	0.8125	0.8125	0	0.5375	0.5368	0	0.5625	0.5152	99	0.5375	0.5156	24	0.7375	0.7324	32
Adversarial (52D)	0.6000	0.5937	64186	0.5875	0.5874	216	0.4250	0.4217	0	0.4875	0.4874	0	0.7500	0.7421	0	0.4125	0.2920	417	0.4000	0.3966	769	0.9875	0.9870	1080
Iris (4D)	1.0000	1.0000	3138	0.9333	0.9326	59	0.9667	0.9680	0	0.9667	0.9680	0	0.9667	0.9680	0	0.9667	0.9680	9	0.9333	0.9327	4	0.9667	0.9680	1
Wine (13D)	1.0000	1.0000	8908	0.9429	0.9444	92	1.0000	1.0000	0	0.9714	0.9710	0	0.9714	0.9696	0	1.0000	1.0000	66	1.0000	1.0000	14	0.9143	0.9148	18
BreastCancer(30D)	0.9292	0.9159	50410	0.9469	0.9369	267	0.9823	0.9790	0	0.9823	0.9790	0	0.9115	0.8965	0	0.9911	0.9894	514	0.9823	0.9786	401	0.9204	0.9076	920




Figura 6: Muestra representativa de las fronteras topológicas 2D proyectadas. Se observa el comportamiento del algoritmo *One-vs-Rest* tejiendo iterativamente colectores de Fourier cerrados alrededor de las nubes de puntos de cada clase. Las superficies evaden elegantemente traslapes no-lineales, encapsulando las distribuciones (*Moons*) sin disrumpir el espacio exterior, una proeza imposible para proyectores lineales convencionales.




Figura 7: Evolución del frente estocástico de Pareto en el paso terminal de NSGA-II. La curva de no-dominancia ilustra visualmente el postulado de la Navaja de Ockham paramétrica: el algoritmo balancea implacablemente individuos que priorizan una tasa de error mínima (eje X) frente a individuos que reducen el sobreajuste acortando la longitud de arco y descartando armónicos excesivos (eje Y).

4.3. Limitación 2: La Maldición de Dimensionalidad

Al probar el algoritmo en *Adversarial Noise (52D)* —círculos 2D inmersos en 50 ejes de ruido uniforme—, todos los modelos de distancias isotrópicas (*k*-NN, SVM, y FM-NSGA-II) fracasaron rotundamente ($\sim 39\text{--}47\%$ Accuracy). La formulación de $d_w(\mathbf{x}, M)$ en $\mathbb{R}^{52}$ fuerza que todas las proyecciones tiendan a la misma magnitud aunque los pesos w_d sean co-evolucionados, ya que el espacio de búsqueda de 52 pesos es demasiado vasto para que el motor genético converja a la solución óptima $w_1 = w_2 = 1, w_{3..52} = 0$ en el tiempo limitado. Solo los Árboles de Decisión triunfaron matemáticamente, ya que sus particiones axiales actúan como *Feature Selection* asintótico estricto.

5. Discusión y Utilidad Práctica

A pesar de las vulnerabilidades expuestas frente al ruido dimensional masivo y la oscilación hiperfrecuente, el **FM-NSGA-II** posee propiedades matemáticas inherentes que lo dotan de una utilidad crítica en dominios donde los algoritmos estándar del estado del arte (como Deep Learning o Random Forests) fracasan conceptualmente:

- Interpretabilidad Analítica Estricta (White-Box):** A diferencia de las Redes Neuronales o SVMs con Kernels RBF, cuyas fronteras de decisión operan como cajas negras algebraicas, el FM-NSGA-II destila una fórmula paramétrica explícita (una Serie de Fourier) para la frontera. Esta trazabilidad matemática es un requisito ineludible en contextos críticos auditables, como diagnósticos médicos y sistemas financieros regulados.
- Extracción Topológica de Contornos (Shape Analysis):** El algoritmo no se limita a trazar un hiperplano divisorio bidireccional; en su lugar, *descubre el volumen geométrico* de las distribuciones. Al tejer variedades cerradas, el modelo permite realizar extracción activa de contornos, una propiedad invaluable en Visión Computacional e Imágenes Médicas (ej. segmentación automática de tumores continuos).
- Detección Intrínseca de Anomalías (Outlier Rejection):** Las SVMs lineales y los Árboles de Decisión dividen el espacio hasta el infinito, clasificando forzosamente cualquier punto distante dentro de una clase conocida. La estrategia del FM-NSGA-II de encerrar localmente las nubes de pun-

tos en colectores cerrados implica que el resto del espacio euclidiano infinito es catalogado naturalmente como espacio exterior. Cualquier dato extremo será evaluado con una distancia topológica alta, dotando al algoritmo de capacidades nativas de Detección de Anomalías.

4. **Inmunidad al Desbalance Extremo de Clases:** En datasets altamente asimétricos, los hiperplanos convencionales tienden a ser “empujados” por la densidad masiva de la clase mayoritaria. Al utilizar arquitecturas independientes *One-vs-Rest*, el FM-NSGA-II encapsula geoméricamente a la clase minoritaria sin que el volumen o la varianza de la clase mayoritaria influyan en los coeficientes topológicos de la variedad menor.

5.1. Ejemplo Práctico: Extracción de la Ecuación Clasificadora

Para ilustrar la principal ventaja analítica del algoritmo (interpretabilidad *White-Box*), extrajimos la variedad topológica real evolucionada por el FM-NSGA-II para la Clase 0 del dataset *Two Moons* utilizando únicamente $H = 2$ armónicos. Tras el entrenamiento, el sistema entregó de forma determinista la siguiente matriz paramétrica óptima codificada en el cromosoma ganador:

$$\mathbf{a}_0 = \begin{bmatrix} 0,0638 \\ 0,6301 \end{bmatrix}, \quad A = \begin{bmatrix} 0,4941 & 0,4433 \\ 0,2347 & -0,0034 \end{bmatrix} \quad (10)$$

$$B = \begin{bmatrix} 0,4635 & 0,4520 \\ -0,3160 & -0,3173 \end{bmatrix} \quad (11)$$

A diferencia de un modelo de Deep Learning, donde el conocimiento está distribuido irrecuperablemente en miles de pesos sinápticos, aquí podemos desarrollar la frontera topológica que envuelve a la “luna inferior” como un par de ecuaciones paramétricas triviales para cualquier parámetro $t \in [0, 2\pi]$:

$$x(t) = 0,0638 + 0,4941 \cos(t) + 0,4635 \sin(t) + 0,4433 \cos(2t) + 0,4520 \sin(2t) \quad (12)$$

$$y(t) = 0,6301 + 0,2347 \cos(t) - 0,3160 \sin(t) - 0,0034 \cos(2t) - 0,3173 \sin(2t) \quad (13)$$

Esta es la forma matemática exacta de la “regla” aprendida. Para clasificar un paciente clínico o una transacción financiera $\mathbf{p} = (x_p, y_p)$, un auditor humano o un sistema de verificación estático simplemente requiere evaluar la distancia mínima desde $\mathbf{p}$ hacia la curva cerrada trazada por $(x(t), y(t))$ y verificar si el punto yace en su interior topológico. Esta extracción garantiza un sistema de decisión 100 % predecible, determinista y matemáticamente demostrable frente a normativas regulatorias.

5.1.1. Extracción con Variedad Angular (Kernel 2)

Si aplicamos el mismo principio de interpretabilidad al nuevo **Angular Manifold** (Hipersuperficie Direccional), el resultado es algebraicamente aún más compacto. Asumiendo una convergencia con $H = 2$ armónicos de Chebyshev, el motor evolutivo podría descubrir el siguiente vector de características óptimo:

$$\mathbf{c} = \begin{bmatrix} 0,12 \\ 0,55 \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} 0,707 \\ 0,707 \end{bmatrix} \quad (14)$$

$$a_0 = 0,50, \quad a_1 = 0,20, \quad a_2 = -0,10 \quad (15)$$

La regla clasificadora extraída no requiere trazar un polígono completo. El modelo proyecta cualquier punto arbitrario $\mathbf{x} = (x, y)$ a un escalar direccional z usando la normalización de Ockham:

$$z = \frac{\mathbf{w} \cdot (\mathbf{x} - \mathbf{c})}{\|\mathbf{x} - \mathbf{c}\|} = \frac{0,707(x - 0,12) + 0,707(y - 0,55)}{\|\mathbf{x} - \mathbf{c}\|} \quad (16)$$

Y el radio dinámico de aceptación se expresa utilizando los polinomios de Chebyshev $T_0(z) = 1, T_1(z) = z, T_2(z) = 2z^2 - 1$:

$$r(\mathbf{x}) = a_0 T_0(z) + a_1 T_1(z) + a_2 T_2(z) = 0,50 + 0,20z - 0,10(2z^2 - 1) \quad (17)$$

El punto se clasifica en la anomalía si $\|\mathbf{x} - \mathbf{c}\| \leq r(\mathbf{x})$. Al depender exclusivamente de un producto punto euclidiano y operaciones algebraicas elementales cuadráticas, la evaluación no solo es humanamente legible de inicio a fin, sino que su despliegue en sistemas embebidos de muy baja potencia (ej. microcontroladores sin FPU) es inmediato, constituyendo una solución superior para hardware de frontera (Edge AI).

6. Conclusión

El ecosistema de clasificadores paramétricos propuesto (**FM-NSGA-II** y su variante rápida **AM-NSGA-II**) demuestra que la clasificación multiclase se puede resolver mediante la evolución paramétrica de superficies topológicas minimizando simultáneamente el error empírico y la complejidad geométrica (Navaja de Ockham). La incorporación de pesos de características co-evolucionados $\mathbf{w}$, el paralelismo multi-núcleo sin bloques, y la proyección hiperplanar mediante series de Chebyshev, constituyen contribuciones arquitectónicas que extienden drásticamente la capacidad adaptativa y la velocidad del modelo (haciéndolo apto para hardware de frontera o Edge AI). Las debilidades teóricas expuestas en los *stress tests* confirman matemáticamente el Teorema *No Free Lunch*: la variación genética no puede modelar alineación de fases puras (XOR hiperfrecuente) y la convergencia de $\mathbf{w}$ en espacios masivamente ruidosos ($\mathbb{R}^{52}$) requeriría más generaciones de las computacionalmente viables. La vía para resolver la

maldición de la dimensionalidad radicaría en un tercer objetivo de selección activa de características estricto (NSGA-III) o en una etapa previa de reducción dimensional.

Referencias

- [1] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: NSGA-II,” *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182-197, 2002.