

Topological Classification via Parametric Manifolds: An Evolutionary and Gradient-Descent Approach (FM, AM, GAM)

Hugo Campos Castro

29 de agosto de 2026

Resumen

Este artículo describe la evolución y diseño de una familia de clasificadores topológicos fundamentados en la optimización de variedades paramétricas en $\mathbb{R}^D$. El enfoque resuelve el problema de clasificación no lineal envolviendo distribuciones de datos en fronteras continuas. Presentamos la evolución cronológica del ecosistema: desde el modelo inicial trigonométrico **Fourier Manifold (FM)**, pasando por la optimización polinomial rápida del **Angular Manifold (AM)**, la formulación completamente auditable del **Generalized Additive Manifold (GAM)**, y culminando en las superficies algebraicas tridimensionales del **Spherical Harmonic Manifold (SHM)**. Inicialmente, la topología de estas variedades fue optimizada estocásticamente mediante el motor genético multi-objetivo **NSGA-II** (optimizando Error vs. Complejidad de curva). Posteriormente, demostramos que las formulaciones AM y GAM poseen propiedades analíticas diferenciables, permitiendo un salto arquitectónico masivo hacia un **Descenso de Gradiente Multi-Objetivo (MGDA)**. Esta transición de NSGA-II hacia MGDA provee aceleraciones de convergencia de magnitudes superiores a 100×, permitiendo tiempos de entrenamiento en fracciones de segundo viables para Edge AI, reteniendo la exactitud topológica y proveyendo métricas transparentes de *Feature Importance*.

1. Introducción: El Viaje Topológico

La separación de clases en espacios no linealmente separables es abordada clásicamente deformando el espacio (ej. truco del kernel en SVMs) o mediante millones de proyecciones distribuidas (Redes Neuronales). El presente trabajo aborda el problema de forma topológica inversa: construimos un colector paramétrico cerrado (*manifold*) $M \subset \mathbb{R}^D$ que se pliega para encapsular a las clases en su espacio topológico nativo, permitiendo extraer explícitamente la ecuación matemática de la frontera (interpretabilidad analítica estricta o *White-Box*).

La arquitectura ha atravesado cuatro fases de evolución funcional, cada una superando las vulnerabilidades de la anterior:

- **Generación 1: Fourier Manifold (FM-**

NSGA-II). La idea original utilizaba series de Fourier para tejer superficies de separación no-lineal. Al no ser analíticamente diferenciable respecto a un error discreto, se acopló al potente motor estocástico multi-objetivo NSGA-II [1]. Aunque logró alta expresividad, la pesada Unidad Aritmética Lógica (ALU) trigonométrica limitó su velocidad.

- **Generación 2: Angular Manifold (AM-NSGA-II)**. Para mitigar el embotellamiento trigonométrico, se formuló una proyección direccional utilizando polinomios recursivos de Chebyshev. Esto aceleró drásticamente la inferencia, pero la evolución estocástica poblacional (NSGA-II) seguía siendo asintóticamente lenta para Big Data.
- **Generación 3: Generalized Additive Manifold (GAM-NSGA-II)**. Se rediseñó el AM para independizar los ejes y dotar al algoritmo de auditabilidad nativa en altísima dimensionalidad, generando una ponderación explícita de *Feature Importance* en hardware analítico médico o financiero.
- **Generación 4: Spherical Harmonic Manifold (SHM-NSGA-II)**. Rompiendo las limitaciones de un único eje direccional de AM, se extraen bases ortonormales tridimensionales $\mathbb{R}^3$ del espacio original $\mathbb{R}^D$ para luego deformarlas volumétricamente usando polinomios de Legendre asociados (Armónicos Esféricos reales). Esto recupera la flexibilidad estocástica del FM pero con la altísima velocidad inferencial del AM.
- **Generación 5: El Salto Diferencial (MGDA)**. El hallazgo crítico de que AM y GAM son diferenciables permitió descartar la selección natural de NSGA-II y adoptar el **Multiple Gradient Descent Algorithm (MGDA)**. Al utilizar gradientes exactos junto con optimizadores modernos (Adam, Focal Loss), el tiempo de convergencia colapsó de decenas de segundos a fracciones de segundo, cristalizando el método.

2. Formulación Topológica (Los Kernels)

2.1. Generación 1: Fourier Manifold (FM)

Definimos la frontera de decisión originaria como una hiper-superficie de Fourier. La aplicación continua $\mathbf{f} : [0, 2\pi) \rightarrow \mathbb{R}^D$ define la coordenada en la dimensión d como:

$$f_d(t) = a_{0,d} + \sum_{k=1}^H (a_{k,d} \cos(kt) + b_{k,d} \sin(kt)) \quad (1)$$

donde $H \in \mathbb{N}$ controla la complejidad oscilatoria. La pertenencia topológica de un punto $\mathbf{x}$ se determina mediante la **distancia con signo radial** respecto al centroide de la clase $\mathbf{c}$:

$$D_S(\mathbf{x}, M) = d_w(\mathbf{x}, \mathbf{c}) - d_w(\mathbf{f}(t^*), \mathbf{c}) \quad (2)$$

donde $t^* = \arg \min_t d_w(\mathbf{x}, \mathbf{f}(t))$ y d_w es la distancia euclidiana ponderada por los co-pesos del modelo $\mathbf{w}$.

Para ilustrar esta mecánica geométrica, si establecemos $H = 0$, la ecuación elimina toda la sumatoria y nos queda simplemente $f_d(t) = a_{0,d}$, un punto. Si $H = 1$, la ecuación introduce un seno y un coseno, trazando un **círculo o elipse perfecta** alrededor de los datos (la frontera de decisión más básica). Sin embargo, al permitir que el algoritmo evolutivo aumente a $H = 3$, se introducen armónicos de alta frecuencia que literalmente *abollanzan* ese círculo original, permitiendo que la curva adquiera formas de herradura, medialuna o espiral para ajustarse herméticamente a un conjunto de datos complejo.




Figura 1: Representación del Cromosoma original de Fourier (FM). Contiene los pesos $\mathbf{w}$ para ponderación de *features* y un arreglo de amplitud trigonométrica dinámico.

2.2. Generación 2: Angular Manifold (AM)

Para combatir el sobrecosto de calcular sin y cos en cada punto, el genotipo AM proyecta una hipersuperficie desde un eje polar $\mathbf{v}$. El radio límite se define mediante polinomios de Chebyshev sobre la proyección direccional $z = \cos(\theta) = \frac{\langle \mathbf{x} - \mathbf{c}, \mathbf{v} \rangle_w}{\|\mathbf{x} - \mathbf{c}\|_w \|\mathbf{v}\|_w}$:

$$R(\mathbf{x}) = a_0 + \sum_{k=1}^H a_k T_k(z) \quad (3)$$

La distancia se simplifica a $D_S = \|\mathbf{x} - \mathbf{c}\|_w - R(\mathbf{x})$, una inferencia de orden $O(D + H)$ sin búsqueda de sub-*parámetros* t .

Consideremos, a modo de ilustración, un conjunto de datos médicos en 30 dimensiones. En lugar de trazar una hiper-esfera compleja en 30D, el algoritmo AM descubre matemáticamente un único vector direccional "maestro" $\mathbf{v}$. Para evaluar a un nuevo paciente $\mathbf{x}$, el modelo computa qué ángulo forma el paciente con respecto a ese vector maestro. Luego, el polinomio de Chebyshev dicta la regla: "Si el paciente está a un ángulo de 45° , su radio límite máximo de pertenencia a la enfermedad es de 2.5 unidades". Hemos comprimido 30 dimensiones a una simple comprobación trigonométrica de un escalar.




Figura 2: Representación del Cromosoma Angular (AM). Comprime la dimensionalidad a un vector direccional y utiliza coeficientes polinomiales para definir el radio límite.

2.3. Generación 3: Gen. Additive Manifold (GAM)

En vez de comprimir toda la dimensionalidad a un único escalar polar z , el GAM Manifold formula un polinomio aditivo independiente por cada característica d . La frontera radial se consolida como:

$$R(\mathbf{x}) = a_0 + \sum_{d=1}^D w_d \left(\sum_{k=1}^H a_{d,k} T_k(\hat{x}_d) \right) \quad (4)$$

donde $\hat{x}_d$ es la característica estandarizada. Esta aditividad aísla el comportamiento por eje, lo que permite extraer el vector $\mathbf{w}$ post-entrenamiento como un índice exacto de *Feature Importance*.

En la práctica, supongamos un problema bidimensional donde predecimos Obesidad usando la Característica 1 (Perímetro Abdominal) y la Característica 2 (Color de Ojos). El modelo entrena un polinomio para $d = 1$ y otro para $d = 2$. Durante el entrenamiento, el motor de optimización descubre que el Color de Ojos ($d = 2$) arroja ruido, por lo que castiga el multiplicador w_2 acercándolo a cero (ej. $w_2 = 0,001$). Al multiplicar el polinomio 2 por 0,001, todo el término se anula en la sumatoria matemática. Así, al revisar el cromosoma final, vemos que $w_1 = 0,99$ y $w_2 = 0,001$, proveyendo

una explicación analítica innegable de cómo el modelo descarta ejes espúreos al tomar sus decisiones.




Figura 3: Representación del Cromosoma Aditivo (GAM). Extiende la representación a una matriz de coeficientes para aislar el comportamiento funcional por cada característica del espacio.

2.4. Generación 4: Spherical Harmonic Manifold (SHM)

Como evolución natural del AM, el SHM levanta la restricción de poseer un solo eje de proyección polar. En su lugar, el cromosoma aprende una matriz ortonormal (mediante Gram-Schmidt ponderado) que forja una base tridimensional $\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} \subset \mathbb{R}^D$. El espacio hiperdimensional es proyectado y condensado localmente hacia una esfera S^2 .

Sobre esa esfera virtual, en vez de un simple polinomio de Chebyshev, modelamos deformaciones volumétricas de frontera usando Armónicos Esféricos Reales (Y_l^m), obtenidos mediante polinomios asociados de Legendre. La ecuación de radio límite de frontera es:

$$r^*(\theta, \phi) = \sum_{l=0}^L \sum_{m=-l}^l c_{l,m} Y_l^m(\theta, \phi) \quad (5)$$

Al igual que en AM y GAM, la pertenencia recae únicamente en validar si la magnitud radial superó al umbral, pero brindando la inmensa invarianza rotacional y capacidad morfológica del FM (superando de esta manera las asimetrías de un simple eje). Su ventaja estructural yace en su cálculo asintótico $\mathcal{O}(D + L^2)$ inferencial sin requerir el cuello de botella que implica la sub-búsqueda del parámetro iterativo de punto mínimo.



Figura 4: Representación del Cromosoma Spherical Harmonic Manifold (SHM). Evoluciona una base proyectiva tridimensional y hasta $(L + 1)^2$ coeficientes esféricos morfológicos.

3. Metodología de Entrenamiento e Inferencia

3.1. Estrategia One-Vs-Rest (OvR)

Para extrapolar la frontera intrínsecamente binaria de una curva cerrada hacia un clasificador Multi-Clase, empleamos la técnica **One-Vs-Rest (OvR)**. Por cada clase K presente en el conjunto de entrenamiento, se entrena un colector paramétrico individual cuya única misión es envolver (etiquetar como $+1$) a la masa de datos de la clase K , rechazando absolutamente todas las demás clases (etiquetadas como -1).

Por ejemplo, en un entorno de diagnóstico de imágenes con clases [Sano, Neumonía, COVID-19], el algoritmo instanciará independientemente tres fronteras topológicas distintas (tres modelos matemáticos M_{Sano} , $M_{Neumonía}$, M_{COVID}). El modelo M_{COVID} tratará a los pacientes de Neumonía y Sanos como una única Clase Enemiga.^{al} momento de forjar su frontera limitante.

3.2. Inferencia Topológica (Distancia Radial con Signo)

Al momento de clasificar puntos nuevos del conjunto de pruebas, cada punto $\mathbf{x}$ se somete a todos los K colectores entrenados. La asignación de clase no recae en un umbral estricto dentro/fuera, sino que se emplea la **Distancia Radial con Signo** D_S :

$$k^* = \arg \min_k (D_S(\mathbf{x}, M_k)) \quad (6)$$

Retomando el escenario médico anterior, supongamos que un nuevo Paciente X ingresa al sistema. El evaluador calcula la distancia de este paciente a los bordes de cada modelo: - D_S en $M_{Sano} = +4,2$ (El paciente está muy "fuera" del radio de sanidad). - D_S en $M_{Neumonia} = -0,5$ (El paciente está "dentro" de la curva de neumonía, por lo tanto es negativo). - D_S en $M_{COVID} = -3,8$ (El paciente está "profundamente hundido" en el centro de la curva COVID).

Al aplicar $\arg \min_k$, el sistema selecciona $-3,8$. El paciente X es clasificado como COVID-19 con extrema certidumbre analítica.

4. Motores de Optimización

4.1. Optimización Estocástica (NSGA-II)

Inicialmente, la parametrización no convexa de los colectores obligó a utilizar un algoritmo evolutivo. Se forjó la optimización de Pareto minimizando dos objetivos conflictivos, $\mathbf{O} = [O_1, O_2]^T$:

- **Objetivo 1 (Error Empírico):** Fracción de puntos mal encapsulados $O_1 = \frac{1}{N} \sum_i \mathbb{I}[y_i \neq \text{sign}(-D_S)]$.
- **Objetivo 2 (Complejidad - Ockham):** Minimiza la longitud de la curva y el número de armónicos

H , con un término de regularización L_1 sobre $\mathbf{w}$ para forzar un barrido de características irrelevantes.

4.2. Salto Diferencial (MGDA)

En las generaciones AM y GAM, la ausencia de una integral no-resoluble habilitó la extracción analítica de los gradientes ∇O_1 y ∇O_2 . Reemplazamos el NSGA-II con **MGDA**, donde la dirección de descenso conjunta óptima $\mathbf{d}$ es:

$$\mathbf{d} = -(\alpha \nabla O_1 + (1 - \alpha) \nabla O_2) \quad (7)$$

Físicamente, este algoritmo actúa como un árbitro geométrico en el espacio de parámetros. Imaginemos que durante el entrenamiento, en la iteración 100, el vector gradiente del Error (∇O_1) le indica a los parámetros del polinomio: *“Aumenten su valor hacia el Norte para abarcar un dato que se nos escapó”*. Sin embargo, el gradiente de Complejidad (∇O_2) reclama: *“Si vamos al Norte, la curva se vuelve muy serpenteante e inestable; debemos ir al Sur”*. El MGDA computa el ángulo de conflicto entre ambos vectores y resuelve matemáticamente el punto de equilibrio óptimo $\mathbf{d}$ (ej. moverse hacia el Oeste), logrando que el modelo reduzca el error empírico sin deteriorar irreparablemente la integridad de la curva topológica.

5. Evaluación Experimental Integral

5.1. Validación Estadística (Wilcoxon)

Para asegurar el rigor científico de nuestras observaciones, la Tabla 4 presenta las pruebas de rangos con signo de Wilcoxon (*Wilcoxon signed-rank test*) evaluadas sobre todos los datasets. Esto confirma de manera concluyente la mejora estadísticamente significativa en velocidad de entrenamiento al adoptar componentes ortogonales y aditivos, y detalla la paridad competitiva en la tasa de aciertos contra modelos consolidados del estado del arte.

5.2. Asimetría Computacional y Velocidad

La Tabla 3 desvela el impacto gigantesco del salto evolutivo. Mientras que el **FM-NSGA-II** original en *TwoMoons* invertía miles de milisegundos penalizado por la trigonometría, la versión polinomial **AM-NSGA-II** lo redujo dramáticamente.

Como se ilustra de manera global en la Figura 6 y Figura 5, el cambio de paradigma estocástico hacia **MGDA** (gradientes analíticos) destrozó los tiempos de forma transversal sin penalizar la exactitud. En un dataset médico denso como *Breast Cancer (30D)*, la familia estocástica NSGA colapsa por la vastedad combinatoria. A su vez, **MGDA-GAM** lo resuelve virtualmente en fracciones de segundo. Esto ubica al **MGDA-GAM** matemáticamente a la par con clasificadores C++ puros (como SVM o Random Forest), con la distinción de que su frontera es completamente extraíble.

5.3. Análisis Visual de Variedades Topológicas

Para comprender cómo el componente matemático se traduce en clasificación física, la Figura 7 muestra los colectores generados superpuestos en el espacio de características bidimensional. El kernel de Fourier (FM) teje envolventes herméticas alrededor del contorno natural de la distribución en forma de luna.

La Navaja de Ockham paramétrica, definida por nuestro segundo objetivo (O_2), se manifiesta visualmente en la Figura 8. Aquí observamos cómo el motor NSGA-II castiga los modelos que desarrollan “tentáculos.” bordes serpenteantes súper-entrenados, obligando a la población final de soluciones a balancearse en un equilibrio perfecto en el Frente de Pareto, desde modelos simples de alto error hasta modelos complejos y precisos.

5.4. Transparencia Extrema: Feature Importance (GAM)

Al aislar la influencia axial mediante la adición de polinomios independientes, el kernel GAM posee auditabilidad plena (White-Box). Extrajimos vectorialmente los pesos de dimensionalidad optimizados de *Breast Cancer (30D)*. Tal y como se detalló teóricamente en la formulación del GAM, los ejes multiplicadores w_d actúan como atenuadores de ruido. Podemos apreciar determinísticamente que el modelo suprimió más del 60 % del ruido diagnóstico y confió masivamente el resultado a factores morfológicos críticos sin requerir aproximaciones post-hoc opacas (como LIME o SHAP).

5.5. El Límite: La Maldición de Dimensionalidad

Al someter a la familia de algoritmos al dataset sintético *Adversarial Noise (52D)* —círculos bidimensionales ofuscados por 50 dimensiones de ruido extremo—, todos los modelos de distancias ponderadas (Topológicos y k -NN) se deprimieron hacia un ~50 % Ac-curacy, simulando el azar. El espacio exploratorio para los pesos del NSGA-II o los gradientes en MGDA fue abrumado por el volumen euclidiano del hipercubo. Los únicos algoritmos capaces de extraer la señal real fueron los Árboles de Decisión, cuya bifurcación ortogonal actúa matemáticamente como un descarte topológico exacto para hiper-planos.

6. Conclusión

A lo largo de este documento, hemos desarrollado y comprobado una tesis clave: **la clasificación no lineal no requiere cajas negras indescifrables**. Como “punto” final, los pilares centrales descubiertos en esta investigación son:

- **Cajas Blancas Geométricas:** Reemplazar hiperplanos abstractos por superficies continuas (colectores) permite resolver topologías en herradura, lu-

Cuadro 1: Precisión global (Accuracy) (una corrida). Se comparan los tres kernels topológicos evolucionados (FM, AM, GAM) contra baselines clásicos en 9 datasets. El mejor valor por dataset se resalta en negrita. GAM-NSGA-II domina en datos tabulares de alta dimensión (Breast Cancer 30D: 97.35 %), mientras FM-NSGA-II mantiene la ventaja en geometrias no-aditivas (Two Moons, Wine). AM-NSGA-II ofrece la mayor velocidad a costa de precisión en alta dimensión.

Dataset	NSGA-Fourier	NSGA-Angular	NSGA-GAM	NSGA-SHM	MGDA-Angular	MGDA-GAM	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 γ =1.00)	Decision Tree (depth=8)
Two Moons (2D)	0.8875	0.8500	0.8375	0.8500	0.9750	0.8875	0.9750	0.9875	0.8500	0.8625	0.9750
Circles (2D)	0.9125	0.5375	1.0000	0.5625	0.8625	0.7750	1.0000	1.0000	1.0000	1.0000	1.0000
Spirals (2D)	0.6875	0.6500	0.6500	0.5500	0.6250	0.6500	1.0000	1.0000	0.6375	0.6375	0.9500
Blobs (2D)	0.9750	1.0000	0.9750	0.9750	0.9875	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Chessboard (2D)	0.5125	0.4375	0.6875	0.4625	0.5625	0.5000	0.8000	0.8125	0.5375	0.5500	0.7375
Adversarial(52D)	0.5000	0.5000	0.5500	0.4750	0.6500	0.7625	0.4250	0.4875	0.5375	0.4125	0.9875
Iris (4D)	0.9667	0.8333	1.0000	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667
Wine (13D)	0.8571	0.9429	0.9714	0.9429	0.9714	1.0000	1.0000	0.9714	0.9714	1.0000	0.9143
BreastCancer(30D)	0.9204	0.9735	0.9292	0.9469	0.9646	0.9558	0.9823	0.9823	0.9115	0.9911	0.9204

Cuadro 2: Macro F1-Score (una corrida). Complementa la Tabla 1 con la métrica F1 para exponer desequilibrios en precisión/recall. GAM-NSGA-II logra F1=0.9682 en Breast Cancer 30D, superando a FM (0.9172) y AM (0.9257).

Dataset	NSGA-Fourier	NSGA-Angular	NSGA-GAM	NSGA-SHM	MGDA-Angular	MGDA-GAM	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 γ =1.00)	Decision Tree (depth=8)
Two Moons (2D)	0.8822	0.8400	0.8298	0.8423	0.9740	0.8834	0.9742	0.9870	0.8420	0.8500	0.9740
Circles (2D)	0.9108	0.4958	1.0000	0.5422	0.8623	0.7744	1.0000	1.0000	1.0000	1.0000	1.0000
Spirals (2D)	0.6402	0.6419	0.6419	0.5401	0.6248	0.6419	1.0000	1.0000	0.6305	0.6305	0.9497
Blobs (2D)	0.9750	1.0000	0.9750	0.9750	0.9875	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Chessboard (2D)	0.5031	0.3043	0.6537	0.4502	0.5569	0.4885	0.7995	0.8125	0.5368	0.5055	0.7324
Adversarial(52D)	0.4842	0.4410	0.5200	0.4682	0.6498	0.7622	0.4217	0.4874	0.7421	0.2920	0.9870
Iris (4D)	0.9680	0.8258	1.0000	0.9680	0.9680	0.9680	0.9680	0.9680	0.9680	0.9680	0.9680
Wine (13D)	0.8524	0.9407	0.9696	0.9407	0.9731	1.0000	1.0000	0.9710	0.9696	1.0000	0.9148
BreastCancer(30D)	0.9076	0.9682	0.9144	0.9411	0.9586	0.9470	0.9790	0.9790	0.8965	0.9894	0.9076




Figura 5: Benchmark Global (Accuracy). Se contrasta la familia Topológica propuesta frente a los modelos clásicos. MGDA conserva o mejora la tasa de exactitud descubierta originalmente por el costoso NSGA-II.




Figura 6: Asimetría Computacional. La adopción del algoritmo MGDA para los kernels polinomiales (GAM y Angular) provee una aceleración colosal respecto a su homólogo biológico estocástico.

na y espiral sin perder la ecuación matemática gobernante.

■ La Trigonometría es Precisa pero Costosa: El

uso de Series de Fourier (FM) proporciona flexibilidad extrema, pero es ineficiente computacionalmente para grandes masas de datos ($O(N \log N)$ real).

Cuadro 3: Costo computacional de entrenamiento (una corrida) (ms). AM-NSGA-II es el kernel más rápido (~ 70 ms en 2D), FM-NSGA-II es el más costoso en alta dimensión ($\sim 57\,000$ ms en 30D), GAM-NSGA-II ofrece un balance intermedio ($\sim 2\,000$ ms en 30D) con mayor precisión que FM en datos tabulares.

Dataset	NSGA-Fourier	NSGA-Angular	NSGA-GAM	NSGA-SHM	MGDA-Angular	MGDA-GAM	k-NN (k=3)	k-NN (k=7)	Gaussian Naive Bayes	SVM-RBF (C=1 $\gamma=1.00$)	Decision Tree (depth=8)
Two Moons (2D)	4329	62	109	452	108	196	0	0	0	75	23
Circles (2D)	5474	64	117	424	110	191	0	0	0	83	26
Spirals (2D)	4947	64	144	384	107	187	0	0	0	72	38
Blobs (2D)	4050	61	101	445	105	177	0	0	0	31	10
Chessboard (2D)	4410	58	181	337	108	189	0	0	0	92	31
Adversarial(52D)	48046	215	2361	1096	989	4261	0	0	0	403	1051
Iris (4D)	2658	74	152	419	193	440	0	0	0	10	1
Wine (13D)	6403	89	229	585	466	1599	0	0	0	54	18
BreastCancer(30D)	41045	187	1347	1153	595	2144	0	0	0	946	954

Cuadro 4: Wilcoxon signed-rank test p -values across benchmark datasets.

Metric	Model A	Model B	p-value	Better (Mean)	Significant ($\alpha=0.05$)
Accuracy	SHM-NSGA-II	AM-NSGA-II (Angular)	0.6875	SHM-NSGA-II	No
Accuracy	GAM-NSGA-II	AM-NSGA-II (Angular)	0.1562	GAM-NSGA-II	No
Accuracy	SHM-NSGA-II	SVM-RBF (C=1 $\gamma=1.00$)	0.0781	SVM-RBF (C=1 $\gamma=1.00$)	No
Accuracy	GAM-NSGA-II	FM-NSGA-II (Fourier)	0.8438	FM-NSGA-II (Fourier)	No
F1 Score	SHM-NSGA-II	AM-NSGA-II (Angular)	0.6875	SHM-NSGA-II	No
F1 Score	GAM-NSGA-II	AM-NSGA-II (Angular)	0.0391	GAM-NSGA-II	Yes
F1 Score	SHM-NSGA-II	SVM-RBF (C=1 $\gamma=1.00$)	0.0781	SVM-RBF (C=1 $\gamma=1.00$)	No
F1 Score	GAM-NSGA-II	FM-NSGA-II (Fourier)	0.6875	GAM-NSGA-II	No
Time (ms)	SHM-NSGA-II	AM-NSGA-II (Angular)	0.0039	AM-NSGA-II (Angular)	Yes
Time (ms)	GAM-NSGA-II	AM-NSGA-II (Angular)	0.0039	AM-NSGA-II (Angular)	Yes
Time (ms)	SHM-NSGA-II	SVM-RBF (C=1 $\gamma=1.00$)	0.0039	SVM-RBF (C=1 $\gamma=1.00$)	Yes
Time (ms)	GAM-NSGA-II	FM-NSGA-II (Fourier)	0.0039	GAM-NSGA-II	Yes




Figura 7: Proyección de los datasets 2D. El colector paramétrico clasifica distribuciones no-lineales determinando la pertenencia mediante su topología inherente.

- **El Aislamiento habilita la Auditoría:** Al transicionar de una trigonometría acoplada (FM) a polinomios independientes por eje (GAM), recuperamos un vector analítico puro capaz de indicar al experto humano exactamente *qué variables* decantaron la clasificación médica o industrial.
- **El Salto Evolutivo a Diferencial:** Reemplazar el motor genético estocástico (NSGA-II) por un algoritmo de gradientes multi-objetivo (MGDA) generó aceleraciones superiores a $100\times$, consolidando esta tecnología paramétrica como una alternativa viable para inferencia embebida (Edge AI).




Figura 8: Frentes estocásticos de Pareto en la convergencia terminal. El cruce entre el Error de Inferencia vs Complejidad Topológica.

Referencias

- [1] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: NSGA-II,” *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182-197, 2002.