

Clasificación Topológica via Variedades Paramétricas

FM $\longrightarrow$ AM $\longrightarrow$ GAM $\longrightarrow$ SHM
NSGA-II $\longrightarrow$ MGDA

Hugo Campos Castro

13 de septiembre de 2026

Contenido de la Presentación

- 1 Motivación y Contexto
- 2 Formulación Matemática: Los Kernels
- 3 Estrategia de Clasificación: OvR e Inferencia
- 4 Motores de Optimización
- 5 Análisis Visual de las Variedades
- 6 Resultados Experimentales
- 7 Interpretabilidad Analítica: Feature Importance
- 8 El Límite y Trabajo Futuro
- 9 Síntesis y Conclusiones

El Problema: Clasificación No Lineal

¿Qué buscamos?

Separar clases en espacios donde **ningún hiperplano** puede hacer el trabajo.

Enfoques clásicos:

- **SVM + kernel trick**: deforma el espacio, pierde interpretabilidad.
- **Redes Neuronales**: millones de parámetros, total caja negra.
- **Árboles**: solo cortes ortogonales — no curvas suaves.

Limitación crítica

Todos los métodos clásicos sacrifican **interpretabilidad** por potencia.


Nuestra propuesta

Construimos un **colector paramétrico cerrado** $M \subset \mathbb{R}^D$ que se *pliega* para **encapsular** la clase objetivo en su topología nativa.

⇒ La ecuación de la frontera es **explícita y extraíble**.

⇒ **White-Box**: total interpretabilidad analítica.

El Viaje Evolutivo: 5 Generaciones



Problema central original:

FM usa $\sin / \cos$ — no diferenciable globalmente para un error discreto $\Rightarrow$ requería optimizador evolutivo (**NSGA-II**).

Hallazgo crítico (Gen. 5):

AM y GAM sí son diferenciables analíticamente $\Rightarrow$ reemplazamos la selección natural por **gradientes exactos (MGDA)**.

Concepto Base: El Colector y la Distancia con Signo

Distancia Radial con Signo D_S

Para un punto $\mathbf{x}$ y un colector M con centroide $\mathbf{c}$:

$$D_S(\mathbf{x}, M) = d_w(\mathbf{x}, \mathbf{c}) - d_w(\mathbf{f}(t^*), \mathbf{c})$$

donde d_w es la distancia euclidiana **ponderada** y t^* el punto más cercano en la curva.

Regla de decisión:

- $D_S < 0 \Rightarrow$ punto **dentro** del colector $\Rightarrow$ clase +1
- $D_S > 0 \Rightarrow$ punto **fuera** del colector $\Rightarrow$ clase -1

Ejemplo intuitivo: 2D

Imagina un círculo alrededor de la clase "Benigno".

Un nuevo paciente $\mathbf{x}$:

- Distancia al centro: 4,2
- Radio del colector en esa dirección: 5,0
- $D_S = 4,2 - 5,0 = -0,8 < 0$

$\Rightarrow$ El paciente está **dentro** $\rightarrow$ Benigno.

Generación 1: Fourier Manifold (FM)

La curva de frontera se parametriza con **Series de Fourier**:

$$f_d(t) = a_{0,d} + \sum_{k=1}^H (a_{k,d} \cos(kt) + b_{k,d} \sin(kt)) \quad (1)$$

- $t \in [0, 2\pi)$: parámetro angular.
- H : armónicos — controla la complejidad oscilatoria.
- d : índice de dimensión en $\mathbb{R}^D$.

Intuyendo H

- $H = 0$: punto fijo (sin curva)
- $H = 1$: **círculo** / **elipse** perfecta
- $H = 3$: .ªbollar.^{el} círculo — luna, herradura, espiral

Limitación

Evaluar $t^* = \arg \min_t d_w(\mathbf{x}, \mathbf{f}(t))$ requiere búsqueda iterativa.

Calcular sin / cos es costoso para Big Data.


No es diferenciable globalmente respecto al error discreto $\Rightarrow$ obligó a usar **NSGA-II**.

Cromosoma FM:


contiene los coeficientes $\{a_{k,d}, b_{k,d}\}$ y los co-pesos $\mathbf{w}$.

Generación 1: Cromosoma FM — Visualización

Cromosoma FM-NSGA-II — Variedad de Fourier Paramétrica



Vector de Pesos $w \in [0, 1]^D$ — Co-evolucionado con los coeficientes



¿Qué vemos?

Los genes (barra de colores) representan los amplitudes $a_{k,d}$, $b_{k,d}$ por dimensión y armónico. El peso w (primera sección) actúa como escala por cada feature. Genéticamente, NSGA-II muta estos genes para que la curva resultante englobe la clase objetivo.

Generación 2: Angular Manifold (AM)

Idea clave: En vez de parametrizar toda la curva, proyectamos $\mathbf{x}$ sobre un **eje polar** aprendido $\mathbf{v}$.

Paso 1 — Coseno proyectado:

$$z = \cos \theta = \frac{\langle \mathbf{x} - \mathbf{c}, \mathbf{v} \rangle_w}{\|\mathbf{x} - \mathbf{c}\|_w \cdot \|\mathbf{v}\|_w}$$

Paso 2 — Radio límite con Chebyshev:

$$R(\mathbf{x}) = a_0 + \sum_{k=1}^H a_k T_k(z)$$

Donde T_k son los **Polinomios de Chebyshev** de primer tipo:

$$T_0 = 1, \quad T_1 = z, \quad T_k = 2z T_{k-1} - T_{k-2}$$

Paso 3 — Decisión:

$$D_S = \|\mathbf{x} - \mathbf{c}\|_w - R(\mathbf{x})$$

Ejemplo médico 30D

El algoritmo descubre el vector “maestro” $\mathbf{v}$ en 30D.

Para un nuevo paciente $\mathbf{x}$:

- 1 Computamos $z = \cos(45^\circ) = 0,707$
- 2 Evaluamos:
 $R = a_0 + a_1(0,707) + a_2(2 \cdot 0,707^2 - 1) + \dots$
- 3 Si $\|\mathbf{x}\|_w = 1,8$ y $R = 2,5$:
 $D_S = -0,7 < 0 \Rightarrow$ clase +1



¡Comprimimos 30D a un escalar!

Ganancia

Inferencia $\mathcal{O}(D + H)$. **Sin** búsqueda de t^* .

Generación 2: Cromosoma AM — Visualización

Estructura del Cromosoma — Angular Manifold



Generación 3: Generalized Additive Manifold (GAM)

Idea clave: Desacoplar las dimensiones — cada eje contribuye **independientemente** al radio límite.
El radio límite se consolida aditivamente:

$$R(\mathbf{x}) = a_0 + \sum_{d=1}^D w_d \left(\sum_{k=1}^H a_{d,k} T_k(\hat{x}_d) \right)$$

donde $\hat{x}_d = \frac{x_d - \mu_d}{\sigma_d}$ es la feature estandarizada.

Propiedades fundamentales:

- **Aditividad** $\Rightarrow$ cada dimensión es separable.
- El vector $\mathbf{w} = [w_1, w_2, \dots, w_D]$ es un índice directo de **Feature Importance**.
- Diferenciable respecto a todos los parámetros $\Rightarrow$ **habilita MGDA**.

Ejemplo: Diagnóstico de Obesidad

Features: $d = 1$ Perímetro Abdominal,
 $d = 2$ Color de Ojos.

Tras el entrenamiento, el optimizador descubre:

$$w_1 = 0,99, \quad w_2 = 0,001$$

El término $w_2 \cdot (\dots) \approx 0$.

Resultado: El modelo descarta matemáticamente el Color de Ojos sin post-hoc (sin LIME, sin SHAP).

White-Box pura

Generación 3: Cromosoma GAM — Visualización

Cromosoma GAM-NSGA-II — Modelo Aditivo Generalizado

Tamaño total: $1 + D \cdot (1 + 2H) = 1 + D \cdot 5$ reales — escala lineal en D



¿Qué vemos?

El cromosoma GAM expande el AM a una **matriz de coeficientes** $D \times H$. Cada fila corresponde a un eje dimensional y cada columna a un armónico polinomial. Los pesos **w** (primera barra) son la Feature Importance directamente legible.

Generación 4: Spherical Harmonic Manifold (SHM)

Motivación: AM/GAM tienen un solo eje de proyección — asimétrico para distribuciones complejas.
¿Cómo recuperar la expresividad de FM con la velocidad de AM?

Paso 1 — Base ortonormal 3D (Gram-Schmidt ponderado):

$$\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} \subset \mathbb{R}^D, \quad \langle \mathbf{v}_i, \mathbf{v}_j \rangle_w = \delta_{ij}$$

Paso 2 — Proyección a S^2 :

$$\theta = \arccos\left(\frac{\langle \mathbf{x} - \mathbf{c}, \mathbf{v}_3 \rangle_w}{\|\mathbf{x} - \mathbf{c}\|_w}\right), \quad \phi = \text{atan2}(p_2, p_1)$$

Paso 3 — Radio con Armónicos Esféricos Reales:

$$r^*(\theta, \phi) = \sum_{l=0}^L \sum_{m=-l}^l c_{l,m} Y_l^m(\theta, \phi)$$

Los Armónicos Esféricos Y_l^m :

$$Y_l^m(\theta, \phi) = N_l^m P_l^{|m|}(\cos \theta) \cdot \begin{cases} \cos(m\phi) & m > 0 \\ \sqrt{2} & m = 0 \\ \sin|m|\phi & m < 0 \end{cases}$$

donde P_l^m son los **Polinomios Asociados de Legendre**.

Complejidad

$\mathcal{O}(D + L^2)$ — sin búsqueda de t^* .

Diferencia con AM

AM usa 1 eje $\Rightarrow$ 1 escalar.

SHM usa 3 ejes $\Rightarrow$ deformación **volu-**

Armónicos Esféricos: Intuición Geométrica

Los Y_l^m son las **funciones propias del Laplaciano en S^2** . Son la base ortonormal del espacio de funciones de la esfera, análogas a los senos y cosenos en la línea recta.

¿Qué controla cada (l, m) ?

- $l = 0$: radio constante (esfera perfecta)
- $l = 1$: deformación dipolar (elongación en un eje)
- $l = 2$: deformación cuadrupolar (forma de donut, silla de montar)
- $l \geq 3$: ondulaciones de alta frecuencia sobre la esfera

Ejemplo: Forma de patata

Queremos una frontera en 3D que tenga una protuberancia al Norte y una hendidura al Este.

$c_{0,0} = 1,0$ (radio base)

$c_{1,0} = 0,3$ (elongar hacia el Norte)

$c_{2,2} = -0,2$ (hundir hacia el Ecuador)

$$r^*(\theta, \phi) = 1,0 \cdot Y_0^0 + 0,3 \cdot Y_1^0 - 0,2 \cdot Y_2^2$$

El resultado: frontera con forma de “**patata deformada**”.

Cromosoma SHM-NSGA-II — Armónicos Esféricos (Spherical Harmonic Manifold)

Tamaño total: $D + 3D + D + (L + 1)^2 = 5D + (L + 1)^2$ reales



One-vs-Rest (OvR) y la Regla de Inferencia

Estrategia OvR

Para K clases, se entrenan K colectores independientes. El colector M_k aprende a encapsular únicamente a la clase k , rechazando todas las demás.

Regla de asignación final:

$$k^* = \arg \min_k (D_S(\mathbf{x}, M_k))$$

El punto pertenece al colector que lo “atrapa” con mayor profundidad (distancia con signo más negativa).

Diagnóstico médico 3 clases

Clases: [Sano, Neumonía, COVID-19].

Para un Paciente X:

$$D_S(M_{\text{Sano}}) = +4,2 \text{ (fuera)}$$

$$D_S(M_{\text{Neumonía}}) = -0,5 \text{ (dentro)}$$

$$D_S(M_{\text{COVID}}) = -3,8 \text{ (muy dentro)}$$

$$\arg \min = -3,8 \Rightarrow \text{COVID-19}$$

La profundidad de $-3,8$ da **certidumbre analítica**.

Motor 1: NSGA-II (Optimización Evolutiva Multi-Objetivo)

Minimizamos **dos objetivos conflictivos** simultáneamente:

$$\mathbf{O} = [O_1, O_2]^T$$

- O_1 — **Error empírico:**

$$O_1 = \frac{1}{N} \sum_i \mathbb{I}[y_i \neq \text{sign}(-D_S)]$$

- O_2 — **Complejidad (Navaja de Ockham):**
Longitud de la curva + número de armónicos H + regularización L_1 sobre $\mathbf{w}$.

NSGA-II mantiene una **población** de soluciones no-dominadas formando el **Frente de Pareto**.

¿Por qué dos objetivos?

Un colector con $O_1 = 0$ (cero error) y $O_2 = \infty$ es un caos de tentáculos que memoriza ruido — **overfitting**.

Un colector con $O_2 = 0$ (mínima complejidad, un círculo) generalmente tiene $O_1 > 0$ — **underfitting**.

NSGA-II nos entrega **todo el espectro** de soluciones de equilibrio.

Pareto $\neq$ óptimo único

El usuario elige el punto del frente que mejor se adapta a sus restricciones.

Motor 2: MGDA — El Salto Diferencial

Condición para usar MGDA: Los kernels AM y GAM son diferenciables:

$\nabla_{\theta} O_1$ y $\nabla_{\theta} O_2$ existen analíticamente.

La dirección de descenso conjunta óptima:

$$\mathbf{d} = -(\alpha \nabla O_1 + (1 - \alpha) \nabla O_2)$$

donde $\alpha \in [0, 1]$ es el **peso de Pareto** que determina el punto del frente.

Actualización de parámetros:

$$\theta_{t+1} = \theta_t - \eta \mathbf{d}$$

Con optimizadores modernos: **Adam**, **Focal Loss**.

El árbitro geométrico

En la iteración 100, los gradientes **conflictúan**:


- ∇O_1 : “Ir al **Norte** para abarcar un dato perdido”
- ∇O_2 : “Ir al **Sur**, la curva se vuelve inestable”

MGDA calcula el ángulo de conflicto y resuelve: ir al **Oeste** — reduce el error sin destruir la topología.

Aceleración




De decenas de segundos (NSGA-II) a **fracciones de segundo** (MGDA). Viable para **Edge AI**

El Frente de Pareto: Visualización



Comparación del Frente de Pareto: MGDA vs NSGA-II


AM-MGDA — Dinámicas de Descenso Multi-Objetivo (MGDA)




NSGA-II: muchas generaciones para converger al frente — cada iteración evalúa cientos de candidatos.

MGDA: sigue el gradiente hacia el frente en **pasos exactos** — convergencia orders of magnitude más rápida.

FM-NSGA-II — Fronteras de decisión




Benchmark Global: Accuracy



- La familia topológica propuesta **igual** o **supera** a los modelos clásicos en la mayoría de datasets.
- MGDA **conserva** la accuracy descubierta por NSGA-II, sin sacrificarla por la velocidad.
- El modelo se desploma en *Adversarial Noise (52D)* — la **maldición de dimensionalidad** afecta a todos los métodos basados en distancia.

Asimetría Computacional: Tiempos de Entrenamiento



- **FM-NSGA-II**: miles de ms en *Two Moons* — la trigonometría es el cuello de botella.
- **AM-NSGA-II**: ya mucho más rápido por Chebyshev sin t^* .
- **MGDA-GAM**: colapsa a fracciones de segundo — $> 100\times$ **más rápido**.
- En *Breast Cancer (30D)*: la familia NSGA colapsa; MGDA lo resuelve al instante.

Validación Estadística: Test de Wilcoxon

¿Qué es el test de Wilcoxon?

Prueba no paramétrica (Demšar, 2006) para comparar dos algoritmos sobre múltiples datasets.

Hipótesis: ¿La diferencia entre modelo A y B es sistemática (real) o al azar?

Criterio: $p < 0,05 \Rightarrow$ diferencia estadísticamente significativa.

Nuestros resultados

Accuracy: $p > 0,05$ en todos los cruces

$\Rightarrow$ No hay diferencia significativa

$\Rightarrow$ Nuestra White-Box no sacrifica precisión.

Tiempo (ms): $p = 0,0039$ en todos

$\Rightarrow$ Diferencia contundente

$\Rightarrow$ La aceleración es estadísticamente irrefutable.

Síntesis estadística

Los colectores topológicos son **irrefutablemente más rápidos** que la generación anterior, y estadísticamente **equivalentes** en precisión a las cajas negras del estado del arte.

White-Box: Feature Importance nativa del GAM

El vector $\mathbf{w} = [w_1, \dots, w_D]$ del cromosoma GAM es el **único y exacto** certificado de importancia de features.


Mecanismo matemático:

$$R(\mathbf{x}) = a_0 + \sum_{d=1}^D \underbrace{w_d}_{\text{importancia}} \cdot \phi_d(\hat{x}_d)$$

Si el optimizador fuerza $w_d \rightarrow 0$, el eje d queda **matemáticamente anulado** en la sumatoria.

No se requiere:

- LIME (aproximaciones locales post-hoc)
- SHAP (valores de Shapley computacionalmente caros)
- Ninguna aproximación — es **exacto**.



Breast Cancer (30D): el modelo suprimió $> 60\%$ de las dimensiones de ruido, concentrando la decisión en los factores morfológicos diagnósticos reales.

La Maldición de Dimensionalidad

Dataset: Adversarial Noise (52D)

Dos círculos en 2D ofuscados por **50 dimensiones de ruido puro**.

¿Qué ocurre?

- En 52D, las distancias euclidianas se **homogenizan** — todos los puntos están a distancias similares (concentración de medidas).
- Los pesos **w** del NSGA-II o los gradientes de MGDA son abrumados por el volumen del hipercubo.
- **Resultado:** $\approx 50\%$ Accuracy — equivalente al azar.

Excepciones:

Solo los **Árboles de Decisión** salvaron la señal — su bifurcación ortogonal actúa como **descarte topológico exacto** de hiperplanos.

Límite fundamental

Los colectores paramétricos basan su inferencia en **distancias radiales**. En alta dimensión con ruido dominante, la señal útil se ahoga en el denominador de la norma euclidiana.

Trabajo Futuro

- Combinar GAM con **selección de features adaptativa**.
- **MGDA para SHM**: requiere el jacobiano de la proyección Gram-Schmidt y la evaluación de Y_l^m .
- Extensión a clasificación **multi-label**

Tabla Comparativa de Generaciones

Modelo	Complejidad	Auditable	Optimizador	Velocidad relativa
FM-NSGA-II	$O(D \cdot H) + \text{búsqueda } t^*$	Parcial	NSGA-II	$1\times$ (base)
AM-NSGA-II	$O(D + H)$	Media	NSGA-II	$\sim 5\times$
GAM-NSGA-II	$O(D \cdot H)$	Total	NSGA-II	$\sim 5\times$
SHM-NSGA-II	$O(D + L^2)$	Media	NSGA-II	$\sim 4\times$
AM-MGDA	$O(D + H)$	Media	MGDA	$> 100\times$
GAM-MGDA	$O(D \cdot H)$	Total	MGDA	$> 100\times$

GAM-MGDA es el punto óptimo del espacio de diseño:
máxima auditabilidad + máxima velocidad.

SHM-NSGA-II es la frontera de expresividad:
recupera la morfología volumétrica de FM con inferencia polinomial.

Conclusiones

① Cajas Blancas Geométricas:

Las variedades paramétricas resuelven topologías en herradura, luna y espiral **sin sacrificar la ecuación matemática gobernante**.

② Trigonometría precisa pero costosa:

FM brinda expresividad extrema pero es **computacionalmente prohibitivo** para Big Data y Edge AI.

③ Aislamiento $\Rightarrow$ Auditoría:

Transicionar de Fourier acoplado (FM) a polinomios independientes por eje (GAM) entrega un vector **w** que indica **exactamente qué variables** tomaron la decisión, sin aproximaciones post-hoc.

④ El Salto Diferencial ($> 100\times$):

MGDA cristaliza la tecnología paramétrica como **alternativa viable para Edge AI**, destruyendo los tiempos del motor evolutivo sin perder precisión topológica.

⑤ Validación estadística irrefutable:

El test de Wilcoxon ($p = 0,0039$ en tiempos) certifica con rigor científico que la aceleración es **sistemática y real**, no un artefacto de un dataset particular.

¿Preguntas?

Hugo Campos Castro

Clasificación Topológica via Variedades Paramétricas

FM $\rightarrow$ AM $\rightarrow$ GAM $\rightarrow$ SHM || NSGA-II $\rightarrow$ MGDA

Repositorio: github.com/uwo-o/FM-NSGA-II



K. Deb et al., “A fast and elitist multiobjective genetic algorithm: NSGA-II,” *IEEE Trans. Evol. Comput.*, vol. 6, no. 2, pp. 182–197, 2002.



J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.



P. Siarry (Ed.), *Metaheuristics*. Springer, 2016.